

Projeto Integrador em Big Data e Inteligência Analítica [202691]

Professor: Francisco Filho

RELATÓRIO FINAL DO PROJETO

PIPELINE DE INTELIGÊNCIA ANALÍTICA EM GASTOS PÚBLICOS

Coleta, modelagem, dashboard interativo e detecção de
despesas atípicas com Machine Learning sobre dados abertos
da Câmara dos Deputados

Aluno: Eric Rocha Pitman Junior

Matrícula: 2486031008

Junho de 2026

1. INTRODUÇÃO

Este relatório consolida as duas entregas do Projeto Integrador da disciplina de Big Data e Inteligência Analítica, documentando o pipeline completo de dados construído sobre a API de Dados Abertos da Câmara dos Deputados: da coleta automatizada via API e armazenamento em banco relacional MySQL, passando pela modelagem dos dados, até a aplicação web interativa com dashboard analítico e um módulo de Machine Learning para detecção de despesas atípicas.

A escolha do tema — gastos parlamentares — se deu pela relevância das informações para estudos de transparência pública e pela disponibilidade de uma API bem documentada, permitindo a aplicação prática de conceitos de Engenharia de Dados, Business Intelligence e Aprendizado de Máquina sobre uma base de dados real.

O documento está organizado seguindo o fluxo do próprio pipeline: origem e justificativa dos dados, estratégia de coleta e tratamento, modelo de dados, arquitetura da aplicação analítica, dashboard, técnica de Machine Learning aplicada, resultados obtidos e, por fim, a declaração detalhada sobre o uso de ferramentas de Inteligência Artificial como apoio ao longo do desenvolvimento.

Objetivo Geral

Desenvolver uma solução analítica capaz de coletar, armazenar, tratar, analisar e interpretar dados públicos relacionados a gastos governamentais, utilizando técnicas de Engenharia de Dados, Business Intelligence e Machine Learning.

Objetivos Específicos

- Consumir dados de uma API pública (Dados Abertos da Câmara dos Deputados);
- Desenvolver rotina automatizada de coleta, com paginação e tratamento de erros;
- Modelar e implementar uma base de dados relacional (MySQL);
- Construir um dicionário de dados e o Diagrama Entidade-Relacionamento (DER);
- Realizar análise exploratória e construir indicadores;
- Construir um dashboard interativo com gráficos e leitura textual automática;
- Aplicar uma técnica de Machine Learning adequada à detecção de anomalias;
- Interpretar os resultados obtidos e discutir limitações;
- Apresentar tecnicamente toda a solução desenvolvida neste relatório.

2. API ESCOLHIDA, ENDPOINTS E ESTRATÉGIA DE COLETA

Foi escolhida a API de Dados Abertos da Câmara dos Deputados (<https://dadosabertos.camara.leg.br/api/v2>), em formato JSON, por reunir critérios decisivos para o projeto: dados reais sobre administração pública, documentação completa dos endpoints e parâmetros, estrutura adequada à construção de um pipeline ETL ponta a ponta e potencial analítico relevante para estudos de transparência pública.

Endpoints utilizados

- /api/v2/deputados — dados cadastrais dos parlamentares (id, nome, siglaPartido, siglaUf);
- /api/v2/deputados/{id}/despesas — despesas associadas a cada parlamentar (tipoDespesa, valorLiquido, dataDocumento, nomeFornecedor, cnpjCpfFornecedor).

Estratégia de coleta e paginação

A coleta foi dividida em duas etapas: primeiro a consulta ao endpoint de deputados, para obter a lista de parlamentares; em seguida, para cada deputado identificado, uma nova consulta ao endpoint de despesas. A API retorna os registros em múltiplas páginas quando o volume é elevado, exigindo paginação automática — o script segue o link 'next' retornado em 'links' até esgotar as páginas disponíveis. Falhas de conexão, timeout e respostas inválidas são tratadas com blocos try/except, registrando o problema sem interromper a execução de todo o processo de coleta.

Tratamentos aplicados aos dados

- Identificação e tratamento de valores nulos (substituição, exclusão ou manutenção controlada, conforme a relevância do campo);
- Conversão de datas de texto para o tipo DateTime, viabilizando análises temporais;
- Conversão de valores monetários para tipos numéricos compatíveis com estatística;
- Remoção de duplicidades via combinações de identificadores e atributos-chave;
- Padronização de nomes de colunas em snake_case (ex.: valorLiquido -> valor_liquido).




Figura 1 - Arquitetura do pipeline ETL: da API da Câmara dos Deputados até a base pronta para análise no MySQL.

3. MODELO DE DADOS E DICIONÁRIO DE DADOS

O modelo relacional foi estruturado em três tabelas: DEPUTADOS (dados cadastrais dos parlamentares), DESPESAS (registros financeiros, em relação 1:N com DEPUTADOS através da chave estrangeira id_deputado) e LOG_IMPORTACAO (tabela de auditoria das execuções do pipeline de coleta, sem chave estrangeira para as demais). Essa separação reduz redundâncias e mantém o modelo simples o suficiente para evoluir caso novas fontes de dados sejam incorporadas no futuro.




Figura 2 - Diagrama Entidade-Relacionamento (DER) da base de dados do projeto.

Dicionário de Dados (principais campos)

Campo	Tipo	Descrição
id_deputado	INTEGER	Identificador único do parlamentar
nome	TEXT	Nome do parlamentar
sigla_partido	TEXT	Partido político
sigla_uf	TEXT	Unidade Federativa
tipo_despesa	TEXT	Categoria da despesa

valor_liquido	REAL	Valor efetivamente pago
data_documento	DATE	Data da despesa
nome_fornecedor	TEXT	Beneficiário do pagamento
cnpj_cpf_fornecedor	TEXT	Documento do fornecedor

Persistência

Os dados tratados são persistidos em banco MySQL através de SQLAlchemy/mysql-connector-python. A escolha do MySQL se justifica pelo suporte a múltiplos usuários e conexões concorrentes, pelos recursos de integridade referencial (chaves primárias, estrangeiras e índices) e pela maior aderência a um cenário de produção real, em comparação a uma solução de armazenamento simplificada.

4. ARQUITETURA DA APLICAÇÃO ANALÍTICA

A camada de apresentação foi construída com Streamlit, permitindo montar uma aplicação web multipáginas inteiramente em Python, sem necessidade de HTML, CSS ou frameworks de frontend dedicados. A aplicação está dividida em sete páginas, acessadas por um menu lateral, cada uma consultando o MySQL de forma independente através da mesma camada de acesso a dados construída na primeira entrega:

- O Projeto — apresentação geral do trabalho;
- Definições do Sistema — documentação da API, do banco, do pipeline ETL e do módulo de Machine Learning;
- O Código Python — código-fonte da coleta, exposto para consulta;
- Importação de Dados — dispara a coleta e a gravação no MySQL sob demanda;
- Dados Importados — exibe em tabela o que já foi salvo no banco;
- Dashboard Informativo — indicadores e gráficos sobre os gastos;
- Análise com Machine Learning — detecção de despesas atípicas;
- Relatório Final do Projeto — leitura e download deste relatório em PDF.

Bibliotecas utilizadas

- requests, pandas, SQLAlchemy, mysql-connector-python — coleta e persistência (Entrega 1);
- streamlit — construção da aplicação web multipáginas e componentes de interface;
- plotly (plotly.express) — gráficos interativos do dashboard e da página de ML;
- scikit-learn (IsolationForest) — detecção de despesas atípicas;
- graphviz — diagramas do pipeline ETL, do DER e do fluxo de Machine Learning.

5. DASHBOARD INFORMATIVO

O Dashboard Informativo reúne os principais indicadores extraídos da base de despesas. O usuário escolhe o ano de referência e todos os números e gráficos da tela são recalculados automaticamente. Entre os indicadores estão o total gasto, a quantidade de despesas, o número de deputados envolvidos e a média de gasto por parlamentar, além de gráficos para os deputados com maior gasto, a distribuição por partido e por estado, as categorias de despesa que mais pesam no total e a evolução mês a mês.





Figura 3 - Dashboard Informativo: indicadores (KPIs) e gráficos de Top 10 Deputados, Gastos por Partido, Gastos por UF e Top Categorias de Despesa (captura real da aplicação em execução, com dados de 2025).

Logo abaixo dos painéis de Top 10 Deputados, Partido, UF e Categoria, foi adicionado um texto calculado automaticamente a partir do próprio recorte exibido, apontando qual deputado, partido, UF e categoria lideram o ano selecionado. O mesmo princípio se aplica à evolução mensal: a aplicação identifica o mês de maior gasto e indica se a tendência entre o início e o fim do período é de alta ou de queda. Como esse texto é recalculado a cada seleção de ano, ele sempre reflete os dados realmente exibidos na tela.



No ano de 2025, **Albuquerque** foi o deputado com maior volume de gastos (R 615.201,36). O partido ****PP**** concentrou o maior total entre as siglas analisadas, e o estado ****SP**** lidera em valor acumulado. Entre as categorias de despesa, ****DIVULGAÇÃO DA ATIVIDADE PARLAMENTAR.**** representa o maior montante, somando R 10.395.320,48.


Evolução Mensal



Figura 4 - Interpretação textual automática dos gráficos e evolução mensal dos gastos (valor e quantidade de despesas por mês), capturas reais da aplicação.

Uma seção que ganhou destaque foi a lista de fornecedores com maior concentração de valores. Ao lado de cada fornecedor, um ícone de lupa abre uma janela com a análise detalhada daquele fornecedor: quantos deputados utilizaram seus serviços, o total pago, a distribuição por UF, os maiores utilizadores e a evolução mensal do gasto — permitindo investigar uma relação específica entre parlamentar e fornecedor sem sair da tela principal.

Relatório Final - Projeto Integrador em Big Data e Inteligência Analítica



O mês 12 registrou o maior volume de gastos do ano (R\$ 2.901.813,31). Comparando o início e o fim do período disponível, a tendência geral de gastos é de alta.

Fornecedores com Maior Concentração de Valores

Fornecedor	Tipo de Despesa	Valor Líquido	Análise
TAM	PASSAGEM AÉREA - SIGEPA	R\$ 1.569.596,54	
LATAM Airlines Brasil	PASSAGEM AÉREA - SIGEPA	R\$ 1.437.634,21	
GOL	PASSAGEM AÉREA - SIGEPA	R\$ 837.602,45	
Gol Linhas Aéreas	PASSAGEM AÉREA - SIGEPA	R\$ 563.447,44	
ON - Z IMPRESSAO, DIVULGACAO & MARKETING DIGITAL LTDA	DIVULGAÇÃO DA ATIVIDADE PARLAMENTAR.	R\$ 347.244,00	
CTA - CLEITON TAXI AEREO LTDA	LOCAÇÃO OU FRETAMENTO DE AERONAVES	R\$ 289.650,00	
AZUL	PASSAGEM AÉREA - SIGEPA	R\$ 282.056,33	
GMB DE CASTRO REIS - ME	DIVULGAÇÃO DA ATIVIDADE PARLAMENTAR.	R\$ 265.765,00	
WEVERSON SARMENTO DA PAIXÃO	DIVULGAÇÃO DA ATIVIDADE PARLAMENTAR.	R\$ 265.368,00	
Facebook Serviços Online do Brasil Ltda.	DIVULGAÇÃO DA ATIVIDADE PARLAMENTAR.	R\$ 249.127,20	

Figura 5 - Fornecedores com maior concentração de valores, com acesso direto à análise detalhada de cada um (captura real da aplicação).

6. MÓDULO DE MACHINE LEARNING - DETECÇÃO DE DESPESAS ATÍPICAS

6.1 Por que Isolation Forest

A técnica escolhida foi o Isolation Forest, do scikit-learn, por três motivos: (1) não exige rótulos prontos indicando despesas irregulares — o próprio algoritmo aprende, de forma não supervisionada, o que se distancia do padrão; (2) é uma técnica consolidada para detecção de outliers em dados tabulares, isolando rapidamente pontos que se afastam do grosso dos dados através de partições aleatórias da árvore de decisão; (3) é leve o suficiente para ser treinado novamente a cada interação do usuário (mudança de ano ou de sensibilidade), sem necessidade de persistir um modelo treinado em disco.

6.2 Como o modelo foi aplicado

Em vez de um único modelo para toda a base, optou-se por treinar um Isolation Forest separado para cada tipo de despesa, já que categorias como combustível, divulgação parlamentar ou passagem aérea têm faixas de valor muito diferentes entre si — um modelo único provavelmente marcaria como atípica qualquer categoria naturalmente mais cara. Para cada categoria com ao menos dez registros no ano selecionado, o modelo usa o valor líquido da despesa como variável de entrada e classifica cada lançamento entre normal e atípico, conforme a sensibilidade (parâmetro contamination) ajustada pelo usuário na tela.




Figura 6 - Fluxo de processamento do módulo de Machine Learning: da base de despesas no MySQL até a classificação final em normal ou atípica.

6.3 Como os resultados são exibidos

Os resultados aparecem primeiro como indicadores resumidos — total de despesas analisadas, quantas foram marcadas como atípicas e o valor somado dessas ocorrências — seguidos por um gráfico de dispersão que mostra as despesas ao longo do tempo, separando visualmente o normal do atípico, e por uma tabela com as maiores despesas atípicas encontradas. Assim como no dashboard, a aplicação interpreta o próprio resultado do modelo: calcula qual percentual das despesas do ano foi marcado como atípico, qual categoria concentra mais ocorrências e qual fornecedor aparece com mais frequência entre os lançamentos destacados.

Página 11

data_documento

Maiores despesas atípicas

Deputado	Partido	UF	Tipo de Despesa	Fornecedor		Valor	Data
Aluisio Mendes	REPUBLICANOS	MA	DIVULGAÇÃO DA ATIVIDADE PARLAMENTAR.	Adriano L Silva Engenharia Serviços e Comércio		R\$ 140.000,00	11/12/2025
Alex Manente	CIDADANIA	SP	DIVULGAÇÃO DA ATIVIDADE PARLAMENTAR.	GWDIAS AGENCIA DE MARKETING DIGITAL LTDA		R\$ 102.000,00	29/12/2025
André Janones	REDE	MG	DIVULGAÇÃO DA ATIVIDADE PARLAMENTAR.	SEVEN COMUNICAÇÃO INTELIGENTE		R\$ 95.200,00	07/02/2026
Adail Filho	MDB	AM	LOCAÇÃO OU FRETAMENTO DE AERONAVES	CTA - CLEITON TAXI AEREO LTDA		R\$ 84.000,00	26/12/2025
Amanda Gentil	PP	MA	DIVULGAÇÃO DA ATIVIDADE PARLAMENTAR.	INDUSTRIA GRAFICA E EDITORA SAO PAULO LTDA		R\$ 82.000,10	19/12/2025
Arlindo Chinaglia	PT	SP	DIVULGAÇÃO DA ATIVIDADE PARLAMENTAR.	BRASPOR GRAFICA E EDITORA LTDA.		R\$ 77.330,00	18/12/2025
Aureo Ribeiro	SOLIDARIEDADE	RJ	DIVULGAÇÃO DA ATIVIDADE PARLAMENTAR.	GRUPODE GRAFICAS LKL LTDA		R\$ 59.150,00	30/04/2025
Antônia Lúcia	MDB	AC	DIVULGAÇÃO DA ATIVIDADE PARLAMENTAR.	MAXIMA IMPRESSAO RAPIDO, MARKETING DIGITAL & DIVULGACAO LT		R\$ 55.200,00	04/09/2025
Antônia Lúcia	MDB	AC	DIVULGAÇÃO DA ATIVIDADE PARLAMENTAR.	ON - Z IMPRESSAO, DIVULGACAO & MARKETING DIGITAL LTDA		R\$ 49.992,00	06/03/2025
Arlindo Chinaglia	PT	SP	DIVULGAÇÃO DA ATIVIDADE PARLAMENTAR.	BRASPOR GRAFICA E EDITORA LTDA.		R\$ 46.129,00	18/12/2025
Andreia Siqueira	PSB	PA	DIVULGAÇÃO DA	WEVERSON SARMENTO DA		R\$	12/03/2025

Figura 8 - Tabela com as maiores despesas atípicas encontradas pelo modelo, com acesso direto à análise detalhada do fornecedor (captura real da aplicação).

6.4 Limitações do modelo

O parâmetro de sensibilidade (contamination) é definido manualmente pelo usuário — o modelo não 'sabe' qual a proporção real de despesas irregulares, apenas isola os pontos mais distantes do padrão observado, na proporção indicada. Categorias com poucos registros no ano selecionado (menos de dez lançamentos) ficam fora da análise, por falta de volume para um padrão confiável. Por fim, uma despesa atípica não é, necessariamente, uma despesa irregular: o resultado deve ser interpretado como um indicativo para investigação adicional, e não como uma conclusão definitiva sobre a regularidade do gasto.

7. RESULTADOS E CONSIDERAÇÕES FINAIS

A execução do pipeline permitiu validar a integração com a API da Câmara dos Deputados, a construção da base relacional no MySQL e o funcionamento de todas as camadas da aplicação analítica — dashboard interativo, leitura textual automática dos gráficos e módulo de Machine Learning. Treinar o Isolation Forest separadamente por categoria de despesa se mostrou a decisão correta: os valores variam tanto entre tipos de despesa que um modelo único provavelmente geraria muitos falsos positivos.

A possibilidade de investigar um fornecedor específico, tanto pelo dashboard quanto pela própria tela de anomalias, aproxima a aplicação de uma ferramenta real de apoio à fiscalização, e não apenas de um exercício acadêmico isolado.

Próximos passos possíveis

- Incorporar variáveis de sazonalidade mensal ou o histórico do próprio fornecedor no modelo;
- Testar modelos de séries temporais para prever gastos futuros;
- Aplicar técnicas de agrupamento (clusterização) para perfis de gasto entre parlamentares.

8. DECLARAÇÃO E TÉCNICAS DE USO DE INTELIGÊNCIA ARTIFICIAL

Em conformidade com a política da disciplina, declara-se que ferramentas de Inteligência Artificial foram utilizadas como apoio ao longo do desenvolvimento deste projeto e na redação deste relatório. A ferramenta principal foi o Claude Code, assistente de codificação da Anthropic (modelo Claude Sonnet), operado diretamente no terminal/editor do aluno. A definição do problema, a escolha das técnicas aplicadas, a validação dos resultados e a revisão de todo o conteúdo produzido permaneceram sob responsabilidade do aluno em todas as etapas.

8.1 Em que etapas a IA foi utilizada

- Implementação do script de coleta (paginação, tratamento de erros e persistência em MySQL), a partir de especificações e decisões definidas pelo aluno;
- Construção das páginas da aplicação Streamlit (dashboard, página de Machine Learning, página de definições do sistema e diagramas Graphviz);
- Geração dos diagramas (ETL, DER e fluxo de Machine Learning) e das capturas de tela reais da aplicação utilizadas neste relatório;
- Apoio na redação e formatação deste relatório final, incluindo a consolidação do texto das duas entregas em um documento único.

8.2 Como a condução pelo aluno se deu na prática

O fluxo de trabalho adotado seguiu um padrão de condução ativa: o aluno definia o objetivo de cada etapa (por exemplo, 'detectar despesas fora do padrão por categoria' ou 'explicar automaticamente o gráfico mais relevante de cada painel'), avaliava as opções técnicas apresentadas pela ferramenta de IA (como a escolha entre treinar um modelo único ou um modelo por categoria de despesa) e decidia qual caminho seguir antes de qualquer código ser escrito. A IA funcionou como um par de programação acelerador: implementou o código sob a orientação do aluno, mas não tomou decisões de modelagem, de arquitetura ou de interpretação dos resultados de forma autônoma.

Após cada trecho de código gerado, o aluno executou a aplicação localmente, validou o comportamento na interface (filtros, gráficos, sensibilidade do modelo, popups de análise de fornecedor) e solicitou ajustes específicos quando o resultado não correspondia ao esperado. Esse ciclo de geração, execução e revisão se repetiu em cada página da aplicação, garantindo que o código final refletisse decisões verificadas pelo aluno, e não apenas a primeira sugestão da ferramenta.

8.3 Técnicas de condução e verificação adotadas

- Especificação incremental: cada solicitação à IA partiu de um objetivo concreto e delimitado (uma página, um gráfico, uma correção pontual), evitando pedir 'o projeto inteiro' de uma só vez e mantendo o controle do aluno sobre cada decisão;
- Validação empírica: toda alteração no dashboard ou no módulo de Machine Learning foi testada na aplicação em execução, com dados reais, antes de ser considerada concluída;

- Revisão crítica do código gerado: trechos de código produzidos pela IA foram lidos e questionados pelo aluno (por exemplo, a justificativa de treinar um modelo por categoria de despesa em vez de um único modelo global);
- Interpretação humana dos resultados analíticos: as conclusões sobre quais deputados, partidos, UFs ou fornecedores se destacam, assim como a leitura sobre as despesas atípicas, foram formuladas e validadas pelo aluno a partir da saída dos modelos — a IA apoiou a automatização do cálculo, mas não a conclusão analítica em si;
- Documentação do processo: as decisões de modelagem e as justificativas técnicas registradas neste relatório foram redigidas a partir da compreensão do aluno sobre o que foi implementado, e não copiadas diretamente de sugestões da ferramenta.

8.4 Limites dessa colaboração

A ferramenta de IA não teve acesso a nenhuma informação fora do escopo do projeto, não tomou decisões finais sobre arquitetura, modelo de dados ou técnica analítica empregada, e todo o conteúdo gerado foi revisado antes de ser incorporado à entrega. O uso de IA seguiu o mesmo princípio de qualquer ferramenta de apoio ao desenvolvimento (como documentação oficial ou bibliotecas de terceiros): acelerar a implementação de decisões já tomadas pelo aluno, e não substituir o raciocínio analítico exigido pela disciplina.

9. REFERÊNCIAS

CÂMARA DOS DEPUTADOS. Dados Abertos da Câmara dos Deputados. Disponível em: <https://dadosabertos.camara.leg.br>. Acesso em: junho de 2026.

MCKINNEY, Wes. Python for Data Analysis. 3. ed. Sebastopol: O'Reilly Media, 2022.

PANDAS DEVELOPMENT TEAM. Pandas Documentation. Disponível em: <https://pandas.pydata.org>. Acesso em: junho de 2026.

PYTHON SOFTWARE FOUNDATION. Python Documentation. Disponível em: <https://docs.python.org>. Acesso em: junho de 2026.

ORACLE CORPORATION. MySQL 9.0 Reference Manual. Disponível em: <https://dev.mysql.com/doc/>. Acesso em: junho de 2026.

SQLALCHEMY. SQLAlchemy Documentation. Disponível em: <https://docs.sqlalchemy.org>. Acesso em: junho de 2026.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, v. 12, p. 2825-2830, 2011. Disponível em: <https://scikit-learn.org>. Acesso em: junho de 2026.

LIU, F. T.; TING, K. M.; ZHOU, Z.-H. Isolation Forest. In: IEEE International Conference on Data Mining, 2008. Disponível em: https://scikit-learn.org/stable/modules/outlier_detection.html. Acesso em: junho de 2026.

STREAMLIT. Streamlit Documentation. Disponível em: <https://docs.streamlit.io>. Acesso em: junho de 2026.

PLOTLY TECHNOLOGIES INC. Plotly Python Open Source Graphing Library. Disponível em: <https://plotly.com/python>. Acesso em: junho de 2026.

ANTHROPIC. Claude Code Documentation. Disponível em: <https://docs.claude.com/claude-code>. Acesso em: junho de 2026.