

PROJETO INTEGRADOR

Pipeline de Inteligência em Gastos Públicos

Curso Tecnólogo em Big Data e Inteligência Analítica

Disciplina: Projeto Integrador

Orientação geral

Este documento apresenta as regras, entregáveis e critérios de avaliação do projeto. A leitura completa da especificação é obrigatória antes do início do desenvolvimento.

1. Apresentação

Projetos de Big Data e Inteligência Analítica não se resumem à criação de gráficos. Antes da visualização dos dados, é necessário compreender sua origem, realizar a coleta, estruturar o armazenamento, tratar inconsistências, organizar o modelo de dados e somente então produzir análises confiáveis.

Neste projeto, o aluno deverá desenvolver um pipeline completo de dados, simulando uma situação próxima à atuação profissional de um analista ou cientista de dados. O trabalho deverá contemplar desde a coleta automatizada de dados públicos por meio de API até a construção de indicadores, dashboards e aplicação de técnicas de Machine Learning.

O tema central será a análise de gastos públicos a partir de bases governamentais abertas.

2. Objetivo Geral

Desenvolver uma solução analítica capaz de coletar, armazenar, tratar, analisar e interpretar dados públicos relacionados a gastos governamentais, utilizando técnicas de Engenharia de Dados, Business Intelligence e Machine Learning.

3. Objetivos Específicos

- consumir dados de uma API pública;
- desenvolver script automatizado de coleta de dados;
- tratar paginação, erros de requisição e inconsistências nos dados;
- modelar e implementar uma base de dados;
- criar um dicionário de dados;
- realizar análise exploratória;
- construir dashboards com indicadores relevantes;
- aplicar uma técnica de Machine Learning adequada ao problema;
- interpretar os resultados obtidos;
- apresentar tecnicamente a solução desenvolvida.

4. APIs Permitidas

O aluno deverá escolher uma das APIs abaixo para desenvolver o projeto:

Opção	API	Possibilidades de Análise
1	Dados Abertos da Câmara dos Deputados	Despesas parlamentares, deputados, partidos, estados, fornecedores e categorias de gasto
2	Dados Abertos do Senado Federal	Despesas de senadores, comparação por parlamentar, partido, estado e tipo de despesa
3	Portal da Transparência do Governo Federal	Despesas públicas federais, órgãos, favorecidos, contratos, convênios e pagamentos

A escolha da API deverá ser justificada no relatório. O aluno deverá explicar por que escolheu determinada fonte de dados e quais perguntas pretende responder com ela.

5. Organização do Projeto

O projeto será dividido em duas entregas:

Entrega	Foco	Principais Entregáveis
Entrega 1	Coleta, estruturação e armazenamento dos dados	Script Python, banco de dados ou estrutura equivalente, DER, dicionário inicial de dados e relatório parcial
Entrega 2	Análise, visualização, Machine Learning e defesa	Dashboard, modelo de Machine Learning, relatório final e vídeo de apresentação

Ponto de atenção

A primeira entrega é a base técnica do projeto. Se a coleta, a modelagem ou o armazenamento estiverem frágeis, a segunda entrega ficará comprometida.

ENTREGA 1 - COLETA, MODELAGEM E ARMAZENAMENTO DOS DADOS

6. Objetivo da Entrega 1

A primeira entrega tem como foco a construção da base técnica do projeto. O aluno deverá demonstrar que consegue obter dados de uma API pública, compreender a estrutura dos dados recebidos, armazená-los corretamente e documentar o processo.

Nesta etapa, o mais importante não é gerar gráficos, mas garantir que os dados estejam disponíveis, organizados, consistentes e prontos para análise.

7. Requisitos da Entrega 1

7.1 Coleta Automatizada de Dados

O aluno deverá desenvolver um script em Python para realizar requisições HTTP à API escolhida.

O script deverá contemplar:

- conexão com a API;
- escolha dos endpoints utilizados;
- extração dos dados em formato JSON ou equivalente;
- tratamento de paginação, quando houver;
- tratamento básico de erros;
- organização dos dados coletados em estruturas tabulares;
- registro ou indicação da quantidade de dados coletados.

Regra importante

Não será aceito apenas o download manual de arquivos. A coleta deverá ser realizada por meio de script.

7.2 Tratamento Inicial dos Dados

Após a coleta, o aluno deverá realizar um tratamento inicial dos dados, incluindo:

- verificação de campos nulos;
- padronização de datas;
- padronização de valores numéricos;
- remoção ou tratamento de registros duplicados, quando necessário;
- conversão adequada dos tipos de dados;
- identificação de campos relevantes para análise posterior.

Datas devem ser tratadas como datas. Valores financeiros devem ser tratados como campos numéricos. Identificadores, como CPF, CNPJ, código de parlamentar ou código de órgão, não devem ser tratados como valores quantitativos.

7.3 Modelagem e Persistência

O aluno deverá armazenar os dados de forma estruturada. Poderão ser utilizadas as seguintes opções:

- banco relacional, como SQLite, PostgreSQL ou MySQL;

- arquivos analíticos estruturados, como Parquet;
- solução em nuvem, desde que documentada.

A modelagem deverá ser apresentada por meio de um Diagrama Entidade-Relacionamento ou representação equivalente.

O relatório deverá explicar:

- quais tabelas ou estruturas foram criadas;
- quais são as chaves primárias;
- quais são as chaves estrangeiras, quando houver;
- como as entidades se relacionam;
- quais campos foram armazenados;
- por que determinados campos foram escolhidos.

Exemplo: em uma análise de despesas parlamentares, pode haver uma tabela de parlamentares, uma tabela de despesas e uma tabela de fornecedores.

7.4 Dicionário Inicial de Dados

O aluno deverá criar um dicionário de dados contendo, no mínimo:

Campo	Tipo de Dado	Descrição	Exemplo
id_parlamentar	Inteiro	Identificador único do parlamentar	12345
nome	Texto	Nome do parlamentar	João da Silva
uf	Texto	Unidade federativa	DF
tipo_despesa	Texto	Categoria da despesa	Passagem aérea
valor_liquido	Numérico	Valor final da despesa	1350.75
data_documento	Data	Data associada ao documento fiscal	2024-05-10

O dicionário deve ser elaborado com base na API escolhida. A tabela acima é apenas um exemplo.

8. Relatório Parcial da Entrega 1

O relatório parcial deverá conter:

1. Introdução;
2. Objetivo da coleta;
3. API escolhida e justificativa;
4. Endpoints utilizados;
5. Explicação do script de coleta;
6. Tratamentos realizados nos dados;
7. Modelo de dados;
8. Dicionário inicial de dados;
9. Evidências da execução;
10. Considerações parciais.

O relatório deverá ser escrito em linguagem técnica, clara e objetiva.

ENTREGA 2 - ANÁLISE, DASHBOARD E MACHINE LEARNING

9. Objetivo da Entrega 2

A segunda entrega tem como foco transformar os dados coletados em informação útil. O aluno deverá realizar análise exploratória, construir indicadores, desenvolver visualizações e aplicar uma técnica de Machine Learning coerente com o problema escolhido.

Nesta etapa, será avaliada a capacidade do aluno de interpretar os dados e comunicar os resultados de forma técnica.

10. Análise Exploratória dos Dados

O aluno deverá apresentar uma análise inicial da base, contendo:

- quantidade total de registros;
- período analisado;
- principais categorias de gasto;
- valores mínimo, máximo, médio e mediano;
- identificação de campos ausentes;
- distribuição dos gastos ao longo do tempo;
- principais parlamentares, órgãos ou favorecidos, conforme a API escolhida;
- fornecedores ou beneficiários com maior concentração de valores.

A análise deve ir além da simples apresentação de números. O aluno deverá explicar o que os dados indicam.

11. Dashboard

O aluno deverá construir um dashboard utilizando uma ferramenta de BI ou biblioteca de visualização de dados.

Poderão ser utilizadas ferramentas como:

- Power BI;
- Looker Studio;
- Metabase;
- Apache Superset;
- Streamlit;
- Dash;
- gráficos em Python com Matplotlib, Plotly ou Seaborn.

O dashboard deverá conter, no mínimo:

- visão geral dos gastos;
- evolução temporal;
- ranking dos maiores gastos;
- gastos por categoria;
- gastos por estado, partido, órgão ou unidade analisada;

- análise de fornecedores ou beneficiários;
- filtros interativos, quando a ferramenta permitir.

O dashboard deve responder perguntas, e não apenas exibir gráficos. Cada visualização deve ter uma finalidade clara.

12. Machine Learning

O aluno deverá aplicar pelo menos uma técnica de Machine Learning adequada à base escolhida.

A técnica deve ser justificada. Não basta executar um algoritmo; é necessário explicar por que ele foi escolhido e o que se pretende descobrir com ele.

12.1 Opção 1 - Clusterização

A clusterização poderá ser utilizada para agrupar parlamentares, órgãos ou fornecedores com padrões semelhantes de gasto.

Exemplos de perguntas:

- Existem grupos de parlamentares com perfis de despesa parecidos?
- Há fornecedores com comportamento semelhante?
- Determinados estados ou partidos apresentam padrões próximos?

Algoritmos possíveis:

- K-Means;
- DBSCAN;
- Clusterização Hierárquica.

12.2 Opção 2 - Detecção de Anomalias

A detecção de anomalias poderá ser utilizada para identificar despesas ou padrões de gasto que fogem do comportamento esperado.

Exemplos de perguntas:

- Existem despesas muito acima do padrão da categoria?
- Há fornecedores com valores muito superiores aos demais?
- Algum parlamentar apresenta comportamento muito diferente do grupo?

Algoritmos possíveis:

- Isolation Forest;
- Local Outlier Factor;
- Z-Score;
- IQR.

12.3 Opção 3 - Regressão

A regressão poderá ser utilizada para estimar o valor de uma despesa com base em variáveis explicativas.

Exemplos de perguntas:

- É possível estimar o valor de uma despesa com base no tipo de gasto, mês, estado, partido ou fornecedor?
- Quais variáveis parecem ter maior influência no valor gasto?

Modelos possíveis:

- Regressão Linear;
- Árvore de Decisão;
- Random Forest;
- XGBoost, se o aluno souber justificar o uso.

12.4 Opção 4 - Classificação

A classificação poderá ser utilizada quando o aluno definir classes de interesse, por exemplo, gasto baixo, médio ou alto.

Exemplos de perguntas:

- É possível classificar uma despesa como comum ou de alto valor?
- Quais variáveis ajudam a prever uma despesa elevada?

Modelos possíveis:

- Regressão Logística;
- Árvore de Decisão;
- Random Forest;
- KNN.

13. Interpretação dos Resultados

O aluno deverá apresentar os resultados do modelo de forma compreensível.

O relatório deverá responder:

- Qual técnica foi utilizada?
- Quais variáveis foram selecionadas?
- Como os dados foram preparados?
- Quais métricas foram utilizadas?
- O resultado faz sentido?
- Quais limitações foram encontradas?
- O modelo realmente contribui para a análise ou apenas executa um algoritmo sem interpretação?

A interpretação será mais importante do que a complexidade do algoritmo.

14. Vídeo de Apresentação

Além do relatório final, o aluno deverá gravar um vídeo de até 10 minutos apresentando o projeto.

O vídeo deverá conter:

11. apresentação do tema e da API escolhida;
12. explicação do pipeline de dados;
13. demonstração do script de coleta;
14. apresentação do banco de dados ou estrutura de armazenamento;
15. demonstração do dashboard;
16. explicação da técnica de Machine Learning utilizada;
17. interpretação dos principais resultados;

18. dificuldades encontradas e melhorias futuras.

O aluno deverá demonstrar domínio do que foi desenvolvido. A apresentação não deve se limitar à leitura de slides.

15. Relatório Final

O relatório final deverá consolidar as duas entregas e conter, no mínimo:

19. Introdução;
20. Objetivos;
21. API escolhida;
22. Metodologia;
23. Coleta dos dados;
24. Modelagem e armazenamento;
25. Dicionário de dados;
26. Tratamento e preparação dos dados;
27. Análise exploratória;
28. Dashboard;
29. Técnica de Machine Learning utilizada;
30. Resultados obtidos;
31. Limitações;
32. Considerações finais;
33. Referências.

O relatório deverá seguir estrutura acadêmica, com texto claro, figuras legíveis, tabelas organizadas e referências das fontes utilizadas.

16. Critérios de Avaliação

Critério	Peso	O que será avaliado
Coleta e pipeline de dados	25%	Funcionamento do script, uso correto da API, paginação, tratamento de erros e organização da coleta
Modelagem e armazenamento	20%	Estrutura do banco ou arquivos, DER, tipos de dados, chaves, organização e dicionário de dados
Análise e dashboard	20%	Qualidade dos indicadores, gráficos, filtros, clareza visual e capacidade de responder perguntas relevantes
Machine Learning	20%	Escolha adequada da técnica, preparação dos dados, métricas, interpretação e coerência dos resultados
Relatório e vídeo	15%	Clareza da documentação, qualidade da apresentação, domínio técnico e capacidade de explicar o projeto

17. Observações Importantes

- O projeto deverá ser desenvolvido preferencialmente em Python.
- O aluno deverá manter o código organizado e comentado.

- O uso de notebooks é permitido, mas o processo de coleta deve estar claro.
- Não será suficiente apresentar gráficos sem explicar os dados.
- Não será suficiente executar um modelo de Machine Learning sem interpretar o resultado.
- O aluno deverá informar as bibliotecas utilizadas.
- O aluno deverá registrar eventuais limitações da API escolhida.
- Trabalhos sem evidência de coleta automatizada poderão perder pontuação.
- Trabalhos sem explicação do modelo de Machine Learning poderão perder pontuação.
- O uso de ferramentas de apoio é permitido, desde que o aluno compreenda e consiga defender o que foi entregue.

18. Entregáveis

18.1 Entrega 1

- Script de coleta dos dados;
- Base de dados ou arquivos estruturados;
- Diagrama Entidade-Relacionamento ou representação equivalente;
- Dicionário inicial de dados;
- Relatório parcial.

18.2 Entrega 2

- Relatório final;
- Dashboard;
- Código do Machine Learning;
- Base tratada;
- Vídeo de apresentação;
- Código-fonte completo do projeto.

19. Checklist de Conferência Antes da Entrega

Item	Conferência
Coleta via API	O script executa a coleta sem depender de download manual?
Paginação e erros	Há tratamento de paginação e falhas básicas de requisição?
Armazenamento	Os dados foram salvos em banco ou estrutura analítica documentada?
Tipos de dados	Datas, valores financeiros e identificadores foram tratados corretamente?
Modelo de dados	O DER ou representação equivalente está claro?
Dashboard	Os gráficos respondem perguntas relevantes?
Machine Learning	A técnica escolhida foi explicada e interpretada?
Vídeo	A apresentação demonstra domínio do código e dos resultados?